Natural Language Processing

Catedrático: Javier Josué Fong Guzmán
Estudiante: Juan Diego Letona Aguilar

Laboratorio #9

Entrega 23 de octubre, 2026



20230285

Laboratorio #9 - Embeddings

I. Introducción

En este laboratorio comparo distintas formas de representar palabras en español. Usé una matriz de co-ocurrencia con PPMI y SVD, Word2Vec y fastText entrenados por mí con 1,137 noticias y con Don Quijote, y los vectores preentrenados fastText SUC (tamaño M, 100 dimensiones, 200,000 palabras). Los comparo con vecinos, similitud, analogías, visualización y clasificación de noticias. Abajo van capturas del notebook con lo más importante.

II. Preparación de los corpus

Normalicé todo a minúsculas, sin puntuación ni números y conservando las tildes, porque SUC está en minúsculas y distingue tildes (españa está en la posición 541 y España no está, méxico está en la 797 y mexico en la 16,941). Con eso el 98.79% de los tokens de noticias y el 97.38% de los del Quijote existen en SUC. No quité stopwords ni lematicé porque deforma la ventana de contexto y SUC tampoco está lematizado. Usé min_count = 2 porque conserva el 98% del texto y elimina casi la mitad de los tipos. Con ventana 2 el corpus de noticias genera 2,252,542 pares de skip-gram y con ventana 5 genera 5,333,292.

Tamaño de cada corpus

corpus	documentos	oraciones	tokens	tipos
Noticias	1,137	19,939	593,044	27,762
Don Quijote	127	9,399	380,962	22,882

Vocabulario del corpus de noticias según min_count

min_count	tamano_vocabulario	tokens_fuera	tokens_fuera_%
1	27,762	0	0.00%
2	15,813	11,949	2.01%
5	8,278	32,013	5.40%

III. Co-ocurrencia, PPMI y SVD

Con conteos crudos la matriz de co-ocurrencia (2,000 x 2,000 con 93.84% de ceros) está dominada por palabras funcionales, por eso inflación y tecnología salen con coseno 0.95. Con PPMI aparecen palabras con contenido y los cosenos bajan a una escala más real. Con TruncatedSVD a 100 dimensiones (24.74% de la varianza) empresa se parece a plataforma, compañía y tecnología, y gobierno a república, regulador y congreso.

Top 10 por PPMI (valor entre paréntesis)

	empresa	gobierno
1	telecomunicaciones (5.45)	corporativo (7.21)
2	llega (5.19)	federal (5.55)
3	especializada (5.11)	sánchez (5.34)
4	líder (4.97)	nacional (5.26)
5	cualquier (4.71)	iván (5.22)
6	estadounidense (4.69)	funcionarios (5.14)
7	colombiana (4.58)	petro (4.75)
8	criterios (4.56)	mexicano (4.66)
9	española (4.47)	estará (4.54)
10	somos (4.23)	llamado (4.51)

Coseno con conteos y con PPMI

palabra_1	palabra_2	coseno_conteos	coseno_ppmi
empresa	compañía	0.9621	0.2499
gobierno	presidente	0.7647	0.1765
banco	crédito	0.5753	0.0880
banco	mujeres	0.4877	0.1039
inflación	tecnología	0.9489	0.0866

IV. Investigación

CBOW predice la palabra central desde el contexto y skip-gram hace lo contrario, por eso skip-gram funciona mejor con palabras poco frecuentes. Negative sampling cambia el softmax sobre todo el vocabulario por una clasificación binaria con unas pocas palabras negativas, con probabilidad σ(v_w · c_c) donde v_w es el vector de la palabra central y c_c el de la palabra de contexto. word2vec guarda una tabla para palabras y otra para contexto y se queda con la de palabras. GloVe usa conteos globales y fastText usa subpalabras, lo que ayuda en español por su morfología. Multiplicar un one-hot por la matriz E equivale a seleccionar una fila, y EmbeddingBag con mode mean promedia la bolsa de palabras de un documento.

V. Word2Vec y fastText sobre las noticias

Entrené un modelo base y cinco variantes de Word2Vec. Con ventana 2 los vecinos son de la misma clase (bancos, instituciones) y con ventana 10 aparecen palabras que solo comparten la noticia (joe, suscríbete). CBOW es más rápido pero peor con palabras poco frecuentes y la dimensión casi no cambia los vecinos. Elegí skip-gram con ventana 2 como mi mejor modelo.

Configuración y tiempo de entrenamiento de cada variante

variante	sg	window	vector_size	min_count	negative	epochs	vocabulario	tiempo_s
base	1	5	100	2	5	15	15,813	55.7
cbow (sg=0)	0	5	100	2	5	15	15,813	20.2
ventana 2	1	2	100	2	5	15	15,813	34.2
ventana 10	1	10	100	2	5	15	15,813	106.5
dimension 50	1	5	50	2	5	15	15,813	58.2
dimension 300	1	5	300	2	5	15	15,813	104.1

[22] Python

5 vecinos más cercanos por variante

	banco	gobierno	empresa	mercado	tecnología	sostenibilidad
base	central, agrario, república, popular, sudameris	congreso, constitucional, gremial, ordena, electo	startup, veridas, emergente, conjuntamente, multinacional	sector, mercados, colombiano, moneda, accionario	computación, tecnológica, autentificación, aplicada, estandarización	descarbonización, estratégicas, creatividad, internacionalización, prioridad
cbow (sg=0)	cordillera, dominicana, supervisor, grupo, serfinanza	congreso, gremial, partido, comité, consejo	plataforma, startup, compañía, iniciativa, convocatoria	país, territorio, sector, alcance, mundo	innovación, sociedad, tecnológica, digitalización, computación	innovación, digitalización, transformación, diversidad, sociedad
ventana 2	central, popular, gnb, sudameris, finandina	congreso, bce, regulador, federal, senado	startup, compañía, criptomoneda, veridas, participada	mercados, sector, conglomerado, ente, producto	computación, internet, utilizará, actualización, software	descarbonización, digitalización, globalidad, innovación, creatividad
ventana 10	central, agrario, finandina, invest, popular	joe, ordena, maduro, ratificado, fundamento	compañía, startup, seré, biotecnología, conjuntamente	colombiano, accionario, sumada, desconocido, laboral	revolucionaria, computación, estandarización, aplicada, neurálgico	ballabriga, medioambiental, prioritario, suscríbete, sociedad
dimension 50	central, agrario, sudameris, gnb, república	congreso, minem, constitucional, gremial, tono	compañía, startup, criptomoneda, plataforma, participada	sector, colombiano, creciente, desconocido, vacancia	estandarización, tecnológica, autentificación, ayudarle, computación	ciso, enfocados, prioridad, prioridades, remodelando
dimension 300	central, agrario, república, popular, sudameris	congreso, constitucional, biden, petro, gremial	compañía, startup, multinacional, criptomoneda, emergente	colombiano, mercados, accionario, sumada, desconocido	computación, esencia, tecnológica, autentificación, estandarización	estratégicas, prioridades, actuación, internacionalización, newsletter

fastText sí construye vectores para palabras fuera del vocabulario (gobirno, privatizaríamos, criptoempresa) y Word2Vec da KeyError. Con el Quijote los vecinos cambian por completo (gobierno pasa de congreso y regulador a ínsula y barataria), así que el significado viene del corpus.

[27] Python

```
gobirno
  en vocabulario de word2vec: False
  en vocabulario de fastText: False
  vector de fastText (primeras 5 dimensiones): [ 0.322  0.108 -0.082  0.303  0.127]
  vecinos fastText: [('gobierno', 0.927), ('gobiernos', 0.76), ('cuaderno', 0.737), ('infierno', 0.698), ('gobernar', 0.687)]
  word2vec: "Key 'gobirno' not present"

privatizaríamos
  en vocabulario de word2vec: False
  en vocabulario de fastText: False
  vector de fastText (primeras 5 dimensiones): [-0.06   0.114  0.424 -0.011  0.345]
  vecinos fastText: [('otorgamos', 0.793), ('facilitamos', 0.788), ('garantizamos', 0.781), ('reforzamos', 0.774), ('imaginamos', 0.
  word2vec: "Key 'privatizaríamos' not present"

criptoempresa
  en vocabulario de word2vec: False
  en vocabulario de fastText: False
  vector de fastText (primeras 5 dimensiones): [0.341 0.733 0.4   0.37  0.182]
  vecinos fastText: [('criptomoneda', 0.785), ('empresa', 0.782), ('cripto', 0.755), ('criptodivisas', 0.751), ('criptografía', 0.73
  word2vec: "Key 'criptoempresa' not present"
```

[25]

Vecinos más cercanos según el corpus de entrenamiento

palabra	vecinos en noticias	vecinos en el Quijote
señor	avicanna, adrian, brazo, dimayor, calderon, civic	jerónimo, mío, bagatele, manderecha, lléguese, suba
dinero	gastar, score, estorbo, guardar, cdt, hurto	dueño, traed, sabéis, pareciéndome, pagaba, capellán
casa	pasiva, teletrabajar, terraza, enfoca, notificación, filtro	aldea, corte, dejé, pueblo, id, hija
gobierno	congreso, constitucional, gremial, ordena, electo, tono	ínsula, condado, pago, barataria, regalo, pague
palabra	letras, fina, escaso, pagas, operamos, estricto	respondelle, hablase, desató, hablar, hablarle, suspirar

VI. Similitud, vecinos y analogías

Mi función de coseno da el mismo valor que similarity de gensim y mi función de analogía coincide con most_similar. Los antónimos salen con similitud alta (en fastText SUC subir y bajar tienen 0.937) porque la similitud distribucional mide contextos compartidos y no sinonimia. En mi conjunto de 20 pares fastText SUC es el más cercano a mi juicio, con Spearman de 0.564. En analogías los modelos propios casi no aciertan y SUC llega a 75% en top 1 y 92% en top 5.

```
[31]
Palabras elegidas: ['gobierno', 'dinero', 'casa', 'tiempo', 'banco']
```

5 vecinos más cercanos por modelo

	SVD sobre PPMI	Word2Vec noticias	Word2Vec Quijote	fa
gobierno	república, regulador, congreso, federal, banco	congreso, bce, regulador, federal, senado	ínsula, condado, pago, barataria, regalo	elgobierno, gobier, gobiern
dinero	punto, liquidez, cuenta, tiempo, momento	dispositivo, reembolso, coche, cajero, desea	dueño, traed, sabéis, pareciéndome, pagaba	dinerito, dineral, centav
casa	coche, vivienda, página, fuerza, marca	pantalla, reformar, horario, pasiva, preparación	aldea, corte, dejé, pueblo, id	mansión, casita, cab
tiempo	lo, tener, mismo, pero, primero	periodo, largos, período, incentivo, prolongado	deseado, anochecía, durante, gastado, día	mucho, rato, cuánto, tien
banco	bbva, grupo, bancolombia, occidente, central	central, popular, gnb, sudameris, finandina	acomodóse, encajó, mantón, túnica, cinta	hipotecario, bancos, ban

```
[32]
```

Similitud coseno de antónimos

	SVD sobre PPMI	Word2Vec noticias	Word2Vec Quijote	fastText SUC
bueno / malo	fuera de vocabulario	0.660	0.668	0.717
subir / bajar	0.544	0.749	0.657	0.937
ganar / perder	fuera de vocabulario	0.675	0.497	0.689
público / privado	0.523	0.673	fuera de vocabulario	0.653
grande / pequeño	fuera de vocabulario	0.445	0.456	0.711

```
Similitud promedio de pares al azar en SUC: 0.207
[34]
```

Correlación de Spearman con mi conjunto de similitud

modelo	pares_usados	pares_fuera_de_vocabulario	spearman	p_valor
SVD sobre PPMI	8	12	0.293	0.4816
Word2Vec noticias	18	2	0.233	0.3530
Word2Vec Quijote	15	5	-0.146	0.6034
fastText SUC	20	0	0.564	0.0096

```
[37]
```

Aciertos en top 1

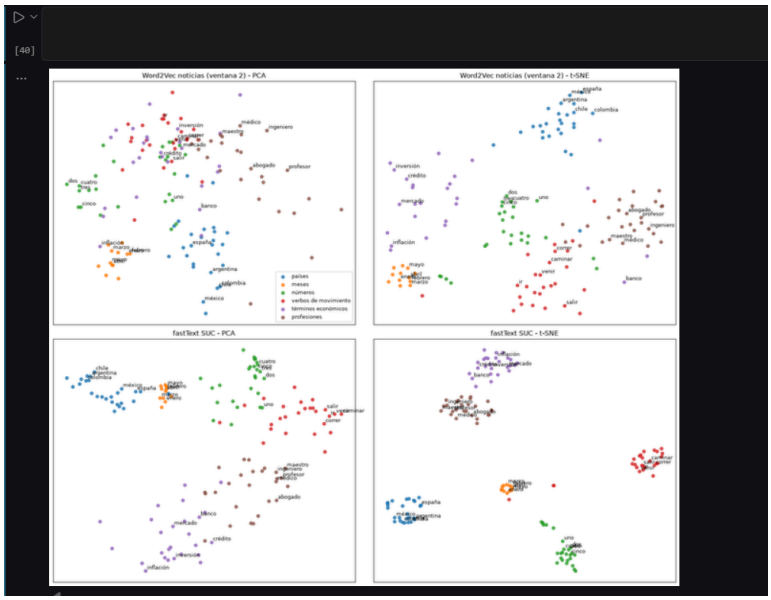
modelo tipo	SVD sobre PPMI	Word2Vec noticias	Word2Vec Quijote	fastText SUC
género	0%	0%	0%	75%
país-capital	0%	0%	0%	50%
país-gentilicio	0%	0%	0%	100%
singular-plural	0%	0%	0%	50%
tiempos verbales	0%	0%	0%	75%
adjetivos m-f	0%	0%	0%	100%
TOTAL	0%	0%	0%	75%

Aciertos en top 5

modelo tipo	SVD sobre PPMI	Word2Vec noticias	Word2Vec Quijote	fastText SUC
género	0%	0%	0%	75%
país-capital	0%	0%	0%	100%
país-gentilicio	0%	0%	0%	100%
singular-plural	25%	25%	0%	75%
tiempos verbales	0%	0%	0%	100%
adjetivos m-f	0%	0%	25%	100%
TOTAL	4%	4%	4%	92%

VII. Visualización del espacio

Los grupos se forman en los dos modelos pero se separan mucho mejor en fastText SUC (silhouette de 0.387 contra 0.183). t-SNE separa mejor que PCA porque conserva vecindarios, aunque la distancia entre grupos no se puede interpretar.



[41]

Separación de los grupos temáticos

modelo	silhouette (coseno)	pureza de los 5 vecinos	pureza países	pureza meses	pureza números	pureza verbos de movimiento	pureza términos económicos
Word2Vec noticias (ventana 2)	0.183	0.783	0.931	1.000	0.792	0.769	0.485
fastText SUC	0.387	0.966	1.000	1.000	0.992	0.931	0.923

VIII. Preguntas de análisis

1. ¿Se parecen los vecinos del modelo de conteos (SVD sobre PPMI) a los de word2vec? Se parecen pero no son iguales. En promedio coinciden 2.88 de los 10 vecinos más cercanos y en el 53.5% de las palabras coinciden al menos 3, cuando por azar serían 0.05. El modelo de conteos es rápido e interpretable pero su matriz crece con el vocabulario (solo usé 2,000 palabras), mientras que word2vec cubre las 15,813. GloVe une ambos enfoques porque ajusta vectores densos a la matriz global de co-ocurrencia.

[42]

```
Palabras comparadas: 2000
Coincidencias promedio en el top 10: 2.88 de 10
Palabras con al menos 3 vecinos en comun: 53.5%
Coincidencia esperada por azar: 0.05 de 10
```

Vecinos en ambos modelos (mismo vocabulario)

palabra	SVD sobre PPMI	Word2Vec noticias
empresa	plataforma, compañía, tecnología, entidad, comunidad, alianza	startup, compañía, ciudad, plataforma, solución, asociación
gobierno	república, regulador, congreso, federal, banco, comisión	congreso, regulador, federal, comité, paquete, anuncio
banco	bbva, grupo, bancolombia, occidente, central, davivienda	central, popular, davivienda, scotiabank, república, colpatria

2. ¿Qué tan lejos quedó mi Word2Vec de fastText SUC y cuánto es tamaño del corpus y cuánto método? Quedó lejos en todo, con pureza de vecinos de 0.828 contra 0.958, Spearman de 0.233 contra 0.564 y analogías de 4% contra 92% en top 5. Al entrenar con 10%, 25%, 50% y 100% de las noticias la pureza sube de 0.505 a 0.828. Entre fastText propio y Word2Vec propio la mejora es de 0.806 a 0.848. Calculo que cerca de 28% de la diferencia es del método y 72% del tamaño y la variedad del corpus, aunque es una estimación aproximada.

[43]

```
Palabras de los grupos presentes en todos los modelos: 101
```

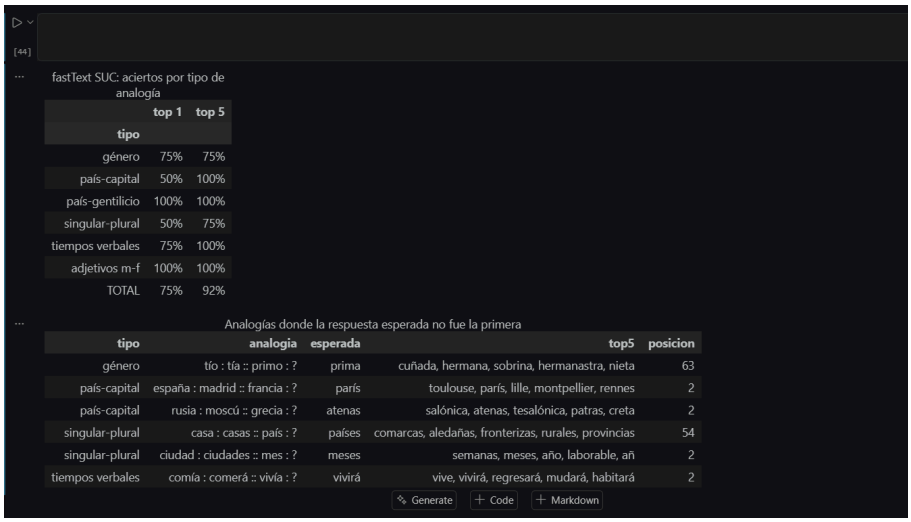
Efecto del tamaño del corpus en la calidad de los vecinos

modelo	tokens de entrenamiento	pureza de los 5 vecinos
10% de las noticias	58,459	0.505
25% de las noticias	147,256	0.687
50% de las noticias	295,023	0.792
100% de las noticias	593,044	0.828
Word2Vec propio, config. base (ventana 5)	593,044	0.806
fastText propio, config. base (ventana 5)	593,044	0.848
fastText SUC	2,600,000,000	0.958

Mi mejor Word2Vec contra fastText SUC

	pureza de los 5 vecinos	spearman con mi conjunto	analogias top 1	analogias top 5	analogias dentro del vocabulario
Word2Vec noticias (ventana 2)	0.828	0.233	0%	4%	62%
fastText SUC	0.958	0.564	75%	92%	100%

3. ¿En qué tipos de analogía funcionó mejor la aritmética vectorial y es el ≈ una igualdad? En fastText SUC funcionó mejor en país-gentilicio y adjetivos (100% en top 1) y peor en país-capital y singular-plural (50%), por ejemplo españa es a madrid como francia es a toulouse antes que parís. El ≈ no es una igualdad porque sin excluir las palabras de la consulta, en 2 de 5 analogías la primera respuesta es una palabra de la consulta (país y alto).



[44]

fastText SUC: aciertos por tipo de analogía

tipo	top 1	top 5
género	75%	75%
país-capital	50%	100%
país-gentilicio	100%	100%
singular-plural	50%	75%
tiempos verbales	75%	100%
adjetivos m-f	100%	100%
TOTAL	75%	92%

Analogías donde la respuesta esperada no fue la primera

tipo	analogia	esperada	top5	posicion
género	tío : tía :: primo : ?	prima	cuñada, hermana, sobrina, hermanastra, nieta	63
país-capital	españa : madrid :: francia : ?	parís	toulouse, parís, lille, montpellier, rennes	2
país-capital	rusia : moscú :: grecia : ?	atenas	salónica, atenas, tesalónica, patras, creta	2
singular-plural	casa : casas :: país : ?	países	comarcas, aledañas, fronterizas, rurales, provincias	54
singular-plural	ciudad : ciudades :: mes : ?	meses	semanas, meses, año, laborable, añ	2
tiempos verbales	comía : comerá :: vivía : ?	vivirá	vive, vivirá, regresará, mudará, habitará	2

Generate + Code + Markdown

4. ¿Cómo cambian los vecinos entre noticias y Quijote y qué problemas trae usar embeddings de otro dominio o época? Cambian por completo, por ejemplo casa pasa de pantalla y horario a aldea y pueblo. El 21.3% de los tokens del Quijote y el 32.6% de los de noticias quedan fuera del vocabulario del otro corpus, y hay formas antiguas como respondelle que un modelo moderno no conoce. Es el mismo problema del tagger del laboratorio 6, un modelo entrenado en un dominio o una época falla en otro.

[45]

Vecinos más cercanos según el corpus (mismo modelo, ventana 2 en noticias y base en Quijote)

palabra	vecinos en noticias	vecinos en el Quijote
señor	dueña, favorito, elemental, adolescencia, camarista, tendero	jerónimo, mío, bagatele, manderecha, lléguese, suba
dinero	dispositivo, reembolso, coche, cajero, desea, monto	dueño, traed, sabéis, pareciéndome, pagaba, capellán
casa	pantalla, reformar, horario, pasiva, preparación, escucha	aldea, corte, dejé, pueblo, id, hija
gobierno	congreso, bce, regulador, federal, senado, comité	ínsula, condado, pago, barataria, regalo, pague
palabra	cancha, castigar, frase, impronta, desregulación, suya	respondelle, hablase, desató, hablar, hablarle, suspirar

```
Tipos en comun: 3,354 (noticias 15,813, Quijote 11,711)
Tokens del Quijote fuera del vocabulario de noticias: 21.3%
Tokens de noticias fuera del vocabulario del Quijote: 32.6%
desta: en noticias=False, en Quijote=True, en SUC=True
dellos: en noticias=False, en Quijote=True, en SUC=True
respondelle: en noticias=False, en Quijote=True, en SUC=False
empresa: en noticias=True, en Quijote=True, en SUC=True
tecnología: en noticias=True, en Quijote=False, en SUC=True
```

5. ¿Los embeddings superaron a TF-IDF en la clasificación y cuándo convino congelar o hacer fine-tuning? No superaron a TF-IDF (0.877). El EmbeddingBag aleatorio (0.883) y SUC con fine-tuning (0.882) quedaron igual y los congelados abajo (0.741 y 0.763), así que convino hacer fine-tuning. Con 10% de los datos todo baja (TF-IDF 0.734, fine-tuning 0.708, congelados cerca de 0.65) y las diferencias entre TF-IDF, aleatorio y fine-tuning ya no se distinguen con seguridad.

[46]

```
Clases: ['Alianzas', 'Innovacion', 'Macroeconomia', 'Otra', 'Regulaciones', 'Reputacion', 'Sostenibilidad']
Noticias de entrenamiento: 909 | de prueba: 228
Baseline TF-IDF listo
Palabras del corpus con vector en SUC: 24187 de 27762
Palabras del corpus con vector en el Word2Vec propio: 15813
EmbeddingBag aleatorio (se entrena) listo
Word2Vec propio (congelado) listo
SUC (congelado) listo
SUC (fine-tuning) listo
```

Clasificación de noticias en el conjunto de prueba (promedio ± desviación de 3 semillas)

modelo	accuracy 100%	f1 macro 100%	accuracy 10%	f1 macro 10%
TF-IDF + regresión logística	0.877 ± 0.000	0.847 ± 0.000	0.734 ± 0.011	0.641 ± 0.047
EmbeddingBag aleatorio (se entrena)	0.883 ± 0.005	0.864 ± 0.013	0.722 ± 0.013	0.623 ± 0.009
Word2Vec propio (congelado)	0.741 ± 0.013	0.687 ± 0.019	0.652 ± 0.031	0.559 ± 0.070
SUC (congelado)	0.763 ± 0.004	0.710 ± 0.001	0.645 ± 0.039	0.547 ± 0.061
SUC (fine-tuning)	0.882 ± 0.004	0.857 ± 0.018	0.708 ± 0.021	0.613 ± 0.028

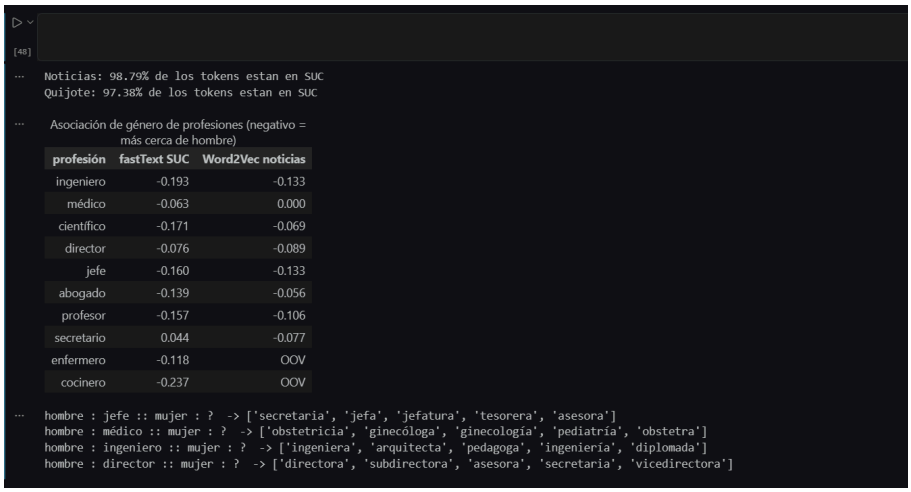
6. La palabra banco tiene un solo vector, ¿qué sentidos se mezclan y cómo lo resuelve BERT? Cada modelo muestra el sentido dominante de su corpus, bancos colombianos en SVD y noticias, la institución financiera en SUC y el asiento en el Quijote. El sentido minoritario queda tapado. BERT calcula el vector de cada palabra con toda la oración, así que separa el banco del parque del banco de las tasas de interés.

[47]

```
SVD sobre PPMI: bbva, grupo, bancolombia, occidente, central, davivienda, popular, caja, también, scotiabank, colombia, bogotá
Word2Vec noticias: central, popular, gnb, sudameris, finandina, bce, coopcentral, agrario, davivienda, scotiabank, bid, serfinanza
Word2Vec Quijote: acomodóse, encajó, mantón, túnica, cinta, desenvainó, desunció, compás, galocha, azogado, escarlata, grajos
fastText SUC: hipotecario, bancos, bank, citibank, monetario, kfw, bancaria, bancario, hsbc, fmi, prestamista, interbank

fastText SUC, vecinos 13 a 40:
banquero, berd, bradesco, inversionista, bankers, barclays, sucursal, bid, banca, securities, bci, tesorería, lloyds, fideicomisario,
SVD sobre PPMI: {'dinero': 0.21, 'crédito': 0.3}
Word2Vec noticias: {'dinero': 0.131, 'crédito': 0.209, 'parque': 0.296, 'sentarse': 0.26, 'río': 0.298}
Word2Vec Quijote: {'dinero': 0.295, 'crédito': 0.429, 'sentarse': 0.524, 'río': 0.385, 'pez': 0.769}
fastText SUC: {'dinero': 0.511, 'crédito': 0.64, 'parque': 0.408, 'sentarse': 0.152, 'río': 0.349, 'pez': 0.307}
```

7. ¿Qué auditaría antes de usar embeddings preentrenados en decisiones sobre personas? Los sesgos, porque en SUC casi todas las profesiones quedan más cerca de hombre y al pedir el equivalente de jefe para mujer el modelo devuelve secretaria. También los textos de origen, otros ejes como nacionalidad, edad y religión, las variables proxy y el error del sistema completo por grupo, con supervisión humana y una forma de apelar.



```
[48]
Noticias: 98.79% de los tokens estan en SUC
Quijote: 97.38% de los tokens estan en SUC

Asociación de género de profesiones (negativo = más cerca de hombre)
```

profesión	fastText SUC	Word2Vec noticias
ingeniero	-0.193	-0.133
médico	-0.063	0.000
científico	-0.171	-0.069
director	-0.076	-0.089
jefe	-0.160	-0.133
abogado	-0.139	-0.056
profesor	-0.157	-0.106
secretario	0.044	-0.077
enfermero	-0.118	OOV
cocinero	-0.237	OOV

```
hombre : jefe :: mujer : ?  -> ['secretaria', 'jefa', 'jefatura', 'tesorera', 'asesora']
hombre : médico :: mujer : ?  -> ['obstetricia', 'ginecóloga', 'ginecología', 'pediatría', 'obstetra']
hombre : ingeniero :: mujer : ?  -> ['ingeniera', 'arquitecta', 'pedagoga', 'ingeniería', 'diplomada']
hombre : director :: mujer : ?  -> ['directora', 'subdirectora', 'asesora', 'secretaria', 'vicedirectora']
```

IX. Conclusiones

El significado de un embedding viene del corpus. Con 593 mil tokens mis modelos sirven para el dominio de las noticias pero no para analogías, y fastText SUC es mucho mejor sobre todo por el tamaño y la variedad de su corpus. PPMI hace falta para que los conteos digan algo y word2vec llega a vecindarios parecidos. Para clasificar noticias TF-IDF fue igual de bueno que los embeddings entrenados, y antes de usar embeddings preentrenados con personas hay que auditar sus sesgos.

https://github.com/JuanDi37/NLP-laboratorio-9